

文字识别数据集生成说明

1. 数据集标注

该标注与目标检测和语义分割的标注有所不同，文字识别的标注是基于图像重命名的形式进行的，重命名格式：`内容+日期.png` 的形式，中间以短下划线分开，如下图一所示。



图一 重命名示例

其中内容指的是 图像中文字的内容，当前只支持大小写英文字母+数字+基本符号，具体可以查看字典 `en_dict.txt`；日期以年、月、日、序号四部分组成，主要用于区分图像内容相同的情况，序号以 0 开始逐步增加。

但是对文件重命名也有一定的局限性，如下图二所示。

文件名不能包含下列任何字符：
\\/:*?"' < > |

图二 无法命名的符号

以上符号无法出现在文件命名中，所以在实际使用过程中如果遇到此类符号就需要另辟蹊径。以符号:举例，我这边的策略是命名的时候用`@@@`代替，然后在文件转化的时候再将`@@@`替换为:。当前转化代码支持这种情况，其他符号还未支持。

2. 数据集生成

2.1 符号验证

该步骤使用的脚本是 `0_符号验证.py`，该脚本主要用于检验重命名地对不对，是不是使用地字符都再在字典 `en_dict.txt`，如果超出了该范围 代码会有提示哪个文件命名地不对，如果显示”符号没问题!!!“则说明所有文件命名正确。

2.1 训练数据生成

该步骤使用的脚本是 `1_训练数据生成.py`，主要是将标注信息解析出来，运行完成后会在文件夹 `rec` 下生成 `rec_gt_train.txt` 和 `rec_gt_test.txt`。

